

随机变量及其概率分布

随机变量

随机变量用于将随机试验的结果数值化

设 Ω 是随机试验的样本空间, 若对每个 $e \in \Omega$, 都对应一个唯一的实数 $X(e)$, 称单值实函数 $X(e)$ 为随机变量

对于任意实数 x , 都对应概率空间中的一个事件 $\{\omega : \omega \in \Omega, X(\omega) \leq x\}$, 即 $X \leq x$

随机变量的取值与概率之间的对应描述称为 X 的概率分布

设 X 是一个随机变量, x 是任意实数, 称函数

$$F(x) = P(X \leq x) (-\infty \leq x \leq \infty)$$

为随机变量 X 的分布函数 (CDF, Cumulative Distribution Function)

CDF 有性质

- 单调: $\forall x_1, x_2 \in \mathbb{R}, x_1 < x_2, F(x_1) \leq F(x_2)$
- 有界: $0 \leq F(x) \leq 1, F(-\infty) = 0, F(\infty) = 1$
- 右连续: $F(x_0 + 0) = \lim_{x \rightarrow x_0 + 0} F(x) = F(x_0)$

一个函数是 CDF \iff 满足上述性质

对任意实数 $a, b (a < b)$ 有

$$P(a < X \leq b) = P(X \leq b) - P(X \leq a) = F(b) - F(a)$$

$$P(X > b) = 1 - P(X \leq b) = 1 - F(b)$$

$$P(X \geq b) = 1 - P(X < b) = 1 - F(b - 0)$$

离散型随机变量

定义

若随机变量 X 的取值为有限个或可列无限个, 则称 X 为离散型随机变量 (discrete random variable)

设离散型随机变量所有可能取值为 $x_1, x_2, \dots, x_n, \dots$ 则

$$P(X = x_k) = p_k, k = 1, 2, \dots$$

称为 X 的**分布律**，可使用表格形式给出

分布律具有性质

- $p_k \geq 0, k = 1, 2, \dots$
- $\sum_k p_k = 1$

分布律即**概率质量函数** (PMF, Probability Mass Function)

设 X 为离散型随机变量，其 PMF $f_X(x)$ 的定义为

$$f_X(x) = P(X = x) = P(\{s \in S : X(s) = x\})$$

常见离散型随机变量

0-1 分布 (Bernoulli Distribution)

随机变量可能取值只有 0, 1, 且

$$P(X = 1) = p, P(X = 0) = 1 - p = q$$

二项分布 (Binomial Distribution)

若随机变量的分布律满足

$$P(X = k) = p_k = C_n^k p^k (1 - p)^{n-k}$$

则称 X 服从参数为 n, p 的二项分布，记为 $X \sim B(n, p)$

n 重伯努利试验中设 A 发生的概率为 p ， A 发生的次数为 X ，则 $X \sim B(n, p)$

对于二项分布的概率最大值

- 当 $(n + 1)p$ 为整数时， p_k 在 $(n + 1)p - 1, (n + 1)p$ 达到最大
- 当 $(n + 1)p$ 不为整数时， p_k 在 $\lfloor (n + 1)p \rfloor$ 达到最大

泊松分布 (Poisson Distribution)

若随机变量 X 的分布律满足

$$p_k = \frac{\lambda^k}{k!} e^{-\lambda}, k = 0, 1, \dots$$

其中 $\lambda > 0$ 为常数，则称 X 服从参数为 λ 的泊松分布，记为 $X \sim P(\lambda)$

泊松分布常用于描述大量试验时稀有事件出现频数的概率。

泊松分布可以用来近似二项分布，当二项分布的参数 n, p 满足 n 很大而 p 很小时，设 $\lambda = np$ ，则有

$$\lim_{n \rightarrow \infty} C_n^k p^k (1-p)^{n-k} = \frac{\lambda^k}{k!} e^{-\lambda}$$

几何分布 (Geometry Distribution)

若随机变量 X 的分布律为

$$p_k = (1-p)^{k-1} p, k = 1, 2, \dots$$

其中 $0 < p < 1$ 为常数，则称 X 服从参数为 p 的几何分布，记为 $X \sim g(p)$

几何分布的含义是 n 重伯努利试验中 A 首次出现时所需的试验次数。

几何分布有**无记忆性**，即

$$P(X = s + t | X > t) = P(X = s)$$

离散型随机变量的分布函数

离散型随机变量的分布函数是一个分段函数，且每一段是左闭右开的区间。下一段相比上一段只增加一个有概率分布的点。

更正式的定义为

$$F(X) = P(X \leq x) = \sum_{x_k \leq x} P(X = x_k) = \sum_{x_k \leq x} p_k$$

连续型随机变量

定义

设随机变量 X 的分布函数为 $F(x)$ ，若存在非负可积函数 $p(x)$ ，对任意实数 x 有

$$F(x) = \int_{-\infty}^x p(t) dt$$

则称 X 为连续型随机变量 (continuous random variable)，称 $p(x)$ 为 X 的概率密度函数 (PDF, Probability Density Function)

PDF 有性质

- $p(x) \geq 0$
- $\int_{-\infty}^{+\infty} p(x) dx = 1$
- 由于 $p(x)$ 为可积函数， $F(x)$ 为连续函数

- 对任意实数 $a, b (a < b)$ 有

$$P(a < X \leq b) = F(b) - F(a) = \int_a^b p(x) dx$$

由于连续型随机变量有特性，即 X 在任意一点 x_0 处取值的概率为 0

对任意 $\Delta x > 0$ 有

$$0 \leq P(X = x_0) \leq P(x_0 - \Delta x < X \leq x_0) = F(x_0) - F(x_0 - \Delta x)$$

分布函数 $F(x)$ 为连续函数，在 $\Delta x \rightarrow 0$ 时上式趋向于 0，故

$$P(X = x_0) = 0$$

根据该性质，连续型随机变量在某个区间取值的概率与区间的开闭无关，故

$$\begin{aligned} P(a < X \leq b) &= P(a < X < b) = P(a \leq X \leq b) = P(a \leq X < b) \\ &= F(b) - F(a) = \int_a^b p(x) dx \end{aligned}$$

- 若 $p(x)$ 在点 x 连续，则分布函数在 $F(x)$ 可导，且 $p(x) = F'(x)$
- 若令 $a = x, b = x + \Delta x$ ，有

$$P(x < X \leq x + \Delta x) = F(x + \Delta x) - F(x) = \int_x^{x+\Delta x} p(x) dx \approx p(x) \Delta x$$

即点 x 处密度函数值越大，在该点附近取值的概率就越大

常见连续型随机变量

均匀分布 (Uniform Distribution)

若随机变量 X 的 PDF 为

$$p(x) = \begin{cases} \frac{1}{b-a} & a < x < b \\ 0 & \text{otherwise} \end{cases}$$

则称 X 在区间 $[a, b]$ 上服从均匀分布，记为 $X \sim U[a, b]$

X 的 CDF 为

$$F(x) = \begin{cases} 0 & x < a \\ \frac{x-a}{b-a} & a \leq x < b \\ 1 & x \geq b \end{cases}$$

均匀分布取值的概率仅与区间长度有关，与区间位置无关

指数分布 (Exponential Distribution)

若随机变量 X 的 PDF 为

$$p(x) = \begin{cases} \lambda e^{-\lambda x} & x \geq 0 \\ 0 & x < 0 \end{cases}$$

其中 $\lambda > 0$ 为常数, 则称 X 服从参数为 λ 的指数分布, 记为 $X \sim E(\lambda)$

X 的 CDF 为

$$F(x) = \begin{cases} 1 - e^{-\lambda x} & x \geq 0 \\ 0 & \text{otherwise} \end{cases}$$

指数分布常用于描述各种寿命的分布

指数分布具有**无记忆性**, 即

$$P(X > s + t | X > t) = P(X > s)$$

正态分布 (Normal Distribution/Gaussian Distribution) ☆

若随机变量 X 的 PDF 为

$$p(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}, -\infty < x < \infty$$

其中 μ, σ 为常数, 则称 X 服从参数为 μ, σ^2 的正态分布, 记为 $X \sim N(\mu, \sigma^2)$

正态分布的 CDF 为

$$F(x) = \int_{-\infty}^x \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(t-\mu)^2}{2\sigma^2}} dt$$

正态分布的密度函数与分布函数的图形有以下特点

- 曲线 $p(x)$ 关于 $x = \mu$ 对称, 且对任意 $b > 0$ 有 $P(X \leq \mu - b) = P(X \geq \mu + b)$
- $x = \mu \pm \sigma$ 为 $p(x)$ 的拐点
- 当 $x \rightarrow \pm\infty$ 时, $p(x) \rightarrow 0$, 即渐近线为 x 轴
- $x = \mu$ 时 $p(x)$ 取得最大值 $\frac{1}{\sqrt{2\pi}\sigma}$, 由于 σ^2 为方差, 故 σ 越大图形越平缓, σ 越小图形越陡峭
- 固定 σ 改变 μ 时曲线形状不变, 而是横向平移

当 $\mu = 0, \sigma = 1$ 时, $X \sim N(0, 1)$, 称 X 服从标准正态分布, 特别地, 将其 PDF 与 CDF 记为

$$\varphi(x) = \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}}$$

$$\Phi(x) = \int_{-\infty}^x \frac{1}{\sqrt{2\pi}} e^{-\frac{t^2}{2}} dt$$

对于其 CDF, 有 $\Phi(-x) = 1 - \Phi(x)$

Proof.

$$\Phi(-x) = \int_{-\infty}^{-x} \frac{1}{\sqrt{2\pi}} e^{-\frac{t^2}{2}} dt$$

做积分变换, 令 $u = -t, dt = -du$

$$\begin{aligned}\Phi(-x) &= \int_{\infty}^x -\frac{1}{\sqrt{2\pi}} e^{-\frac{u^2}{2}} du \\&= \int_x^{\infty} \frac{1}{\sqrt{2\pi}} e^{-\frac{u^2}{2}} du \\&= 1 - \int_{-\infty}^x \frac{1}{\sqrt{2\pi}} e^{-\frac{u^2}{2}} du \\&= 1 - \Phi(x)\end{aligned}$$

这一性质对于所有 x 均成立

☆ 若随机变量 $X \sim N(\mu, \sigma^2)$, 则 $Z = \frac{X-\mu}{\sigma} \sim N(0, 1)$

Proof.

$$\begin{aligned}P(Z \leq x) &= P\left(\frac{X-\mu}{\sigma} \leq x\right) \\&= P(X \leq \sigma x + \mu) \\&= \int_{-\infty}^{\sigma x + \mu} \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(t-\mu)^2}{2\sigma^2}} dt\end{aligned}$$

两边同时求导, 利用积分变限函数求导性质

$$(P(Z \leq x))' = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{x^2}{2}} \sigma = \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}} = \varphi(x)$$

即 Z 的 PDF 为 $\varphi(x)$, 根据定义, $Z \sim N(0, 1)$

根据以上重要性质, 可得对于 $X \sim N(\mu, \sigma^2)$

$$\begin{aligned}F(x) &= P(X \leq x) = \Phi\left(\frac{x-\mu}{\sigma}\right) \\P(a < X < b) &= \Phi\left(\frac{b-\mu}{\sigma}\right) - \Phi\left(\frac{a-\mu}{\sigma}\right)\end{aligned}$$

3σ 法则: $X \sim N(\mu, \sigma^2)$ 在取值时落入 $[\mu - 3\sigma, \mu + 3\sigma]$ 的概率超过 99.7%

随机变量函数的分布

设 X 是随机变量, $y = g(x)$ 是普通实函数, 则令随机变量 Y 在 X 取 x 时取 $g(x)$, 记为 $Y = g(X)$, Y 作为一个随机变量, 也有自己的概率分布

离散型随机变量

设 X 是离散型随机变量, 其分布律为

$$P(X = x_k) = p_k, k = 1, 2, \dots$$

则对于 X 的函数 $Y = g(x)$, 当 X 取 x_k 时 Y 取 $y_k = g(x_k)$, Y 也是离散型随机变量

当 $y_1, y_2, \dots, y_k, \dots$ 取值各不相同, 有

$$P(Y = y_k) = P(Y = g(x_k)) = P(X = x_k) = p_k$$

若 $y_1, y_2, \dots, y_k, \dots$ 中有取值相同的, e. g. $y_i = y_j$, 即 $g(x_i) = g(x_j)$, 则

$$P(Y = y_i) = P(Y = g(x_i) \cup Y = g(x_j)) = P(X = x_i) + P(X = x_j) = p_i + p_j$$

即多个 y_k 取值相同时, 应当把对应的概率加起来

连续型随机变量

分布函数法: 先求 Y 的分布函数 $F_Y(y)$

$$F_Y(y) = P(Y \leq y) = P(g(x) \leq y) = \int_{x:g(x) \leq y} p_X(x) dx$$

然后根据积分变限函数的求导法则求得

$$p_Y(y) = F'_Y(y)$$

公式法:

设随机变量 X 的可能取值范围为 (a, b) , X 的 pdf 为 $p_X(x)$, $a < x < b$, 其中 a 可为 $-\infty$, b 可为 $+\infty$, 设 $y = g(x)$ 处处可导, 且严格单调 (恒有 $g'(x) < 0$ 或 $g'(x) > 0$), 则 $Y = g(X)$ 为连续型随机变量, 且其 pdf 为

$$p_Y(y) = \begin{cases} p_X[g^{-1}(y)] \cdot |g^{-1}(y)|' & \alpha < y < \beta \\ 0 & \text{o. t.} \end{cases}$$

其中 $\alpha = \min\{g(a), g(b)\}$, $\beta = \max\{g(a), g(b)\}$, $g^{-1}(y)$ 为 $g(x)$ 反函数

公式法不如分布函数法泛用